

KAMP 제조AI데이터셋 활용 권한

No. GB20260616-PU1781497920-20768



⚠ 제조AI데이터셋 활용 주의사항

연구/공식적으로 사용하실 때에는 꼭 아래와 같이 'KAMP 출처(reference)'를 남겨주시고, 인용 시 활용한 내용과 문서 등은 아래 이메일로 보내주시기를 바랍니다.
(E-mail : kamp@kaist.ac.kr)

국문 출처 표기 양식

중소벤처기업부, Korea AI Manufacturing Platform(KAMP), 제조AI데이터셋 제목, 수행기업, 데이터 셋등록일, KAMP URL

제조AI데이터셋 개요

제조AI데이터셋명 : 사출성형기 제조AI데이터셋

업종 : 사출성형 | **목적** : 생산공정 최적화 | **유형** : csv

수집 공정·설비 : 사출 5, 6호기

제조데이터셋 수집 방법 : - PLC를 통한 사출조건 수집 - 생산실적 데이터 양품, 불량 수집

제조데이터셋 활용 방법 : - 독립변수, 종속변수 상관관계분석 - K-MEANS 군집분석

수행기업 : 대웅알티(주)-주식회사 팔피엠

등록일 : 2025-03-27

이용자 정보

회원 ID : MSS_wer1101

다운로드일 : 2026-06-16 10:22:35

활용목적 : 제조AI 교육 및 강의

인공지능 제조 플랫폼(KAMP, Korea AI Manufacturing Platform)에서 다운로드한 제조AI데이터셋의 저작권을 위하여 문서 고유 번호와 워터마크를 부여하여, 해당 문서의 표준을 준수하였음을 증명합니다.

운영기관 : KAIST 제조AI빅데이터센터

주소 : 대전광역시 유성구 문지로 193 KAIST 문지캠퍼스 행정동

전화번호 : 042-350-1331 | 이메일 : kamp@kaist.ac.kr

대웅알티(주)

2023년도 AI 솔루션 실증 지원사업
기술검증결과서

2023. 11. 30

(주)팔피엠

목 차

1. AI 솔루션 실증 배경	1
2. 검증 제조데이터셋 개요	3
3. AI 솔루션 현장적용 결과	9
4. 성과지표 측정 방법	10
5. 성과지표 측정 결과	11
6. 확장가능성 및 향후 계획	15



1. AI 솔루션 실증 배경

□ 공정/설비 개요

- 대웅RT는 자동차 및 산업용 고무 제품을 전문적으로 생산하는 기업으로 벤처기업, 이노비즈 등 우수한 기술력의 제품을 생산/판매하고 있으나, 현재 전기 가동차로 전환되면서 주력 제품인 고무제품이 감소하고 플라스틱 제품으로 변환되고 있어, 새로운 먹거리인 전기차용 플라스틱 사출 제품으로 업종변환 필요.
- 현대자동차 SQ 2차 벤더로 자동차용 고무제품 및 전기차용 O-RING제품을 현대 및 기아자동차에 납품하고 있고, 보유기술로는 Sealing System 및 Seal의 기초기술(형상설계기술, 재질 신소재 설계 기술) 및 싺 제조에 관한 생산기술(금형설계 제작 기술, 고정도 성형기술)등을 보유하고 있음.



대웅RT 주요 생산제품

- 일본 하라다싺기연(주)와 기술제휴계약을 체결하여, 연구와 생산분야의 유기적인 조화를 바탕으로 끊임없는 제품의 품질, 공법, 시스템 개선뿐 아니라 신제품 개발을 위한 연구 활동을 지속해서 추진하고 있고, 진동 소음 절단용 패트 등 다수의 지식 재산을 보유하고 있음.

□ 현장문제 정의

○ 문제점

- 내연 기관 차량의 감소와 전기차 증가에 따른 회사 매출감소
 - 최근 '22년 매출성장률은 46%로 증가하였으나 영업이익률이 2%로 미흡하며, 이는 제조원가율의 증가(원재료비의 증가 등)에 기인, 원가절감, 불량률 개선 등 생산효율성 개선이 시급함.
 - 주요 공정인 사출성형 공정은 다품종 소량, 생산 시스템으로 사출기 대부분 자동화이나, 일부 수동으로 혼용되어 운영되어 생산 효율성이 저하
 - 사출 공정은 생산 시 다양한 사출조건 문제가 발생하여 사출 설비의 비가동시간이 길고 LOSS가 많아 불량률이 증가되고 있음
 - 제품의 개발 및 품질개선을 위한 비용 최소화로 최소비용 투자로 최대 효율을 낼 수 있는 기능의 필요.

| ○ 사출 불량률의 원인



- 제품의 다변화에 따른 통합생산관리 시스템(MES)이 일부 사출공정이 적합하지 않아 정보 분석의 어려움
 - 통합생산관리 시스템(MES)과 사출공정 품질을 결정하는 조건의 일부항목만 관리되고 있고, 일부항목은 작업자가 수기 관리로 인한 전체 데이터 취합이 되고 있지 않음.
 - 사출 제품 생산 품질데이터의 분석정보를 제공하지 않아 불량 조건과 양품 조건 분석을 위해 많은 시간소모
- 전문가의 의존한 제품 생산조건 관리
 - 사출전문 기사에 의존한 조건관리로 인력문제 발생 시 사출 제품의 대량 불량, 생산 불량 등의 생산 문제 발생
 - 지속적으로 발생하는 전문인력의 수급문제로 인해 일반 생산인력이 시스템을 통한 도움으로 전문인력으로 변화할 수 있는 솔루션 필요.



2. 검증 제조데이터셋 개요

- 수 집 업 종 : 사출성형
- 수 집 목 적 : 사출성형 공정에서 발생하는 품질 문제를 AI 기반 공정 불량 예측
- 수 집 공정·설비 : 사출 5,6호기
- 제조데이터셋 형태 : CSV파일
- 제조데이터셋 개수 : 72,762개
- 제조데이터셋 용량 : 5.5 MB

No	구분	내용
1	제조데이터셋 구축 배경	- 내연 기관 차량의 감소와 전기차 증가에 따른 회사 매출감소 - 제품의 다변화에 따른 통합생산관리 시스템(MES)이 일부 사출공정이 적합하지 않아 정보 분석의 어려움 - 전문가의 의존한 제품 생산조건 관리
2	제조데이터셋 수집 방법	- PLC를 통한 사출조건 수집 - 생산실적 데이터 양품, 불량 수집
3	제조데이터셋 주요 변수	사출속도4, 사출압력4, 사출거리1, 히터온도2
4	제조데이터셋 활용 방법	가. 상관분석 - 독립변수, 종속변수 상관관계분석: 총 양불구분, 쿠션위치, 최대사출속도, 평균배압, 유압: 히터1 전동: 히터3, 유 압: 히터2 전동: 히터4, 호퍼온도, 금형온도1, 금형온도2, 사출속도4등 나. K-MEANS 군집분석 - 독립변수에 대한 군집분석


□ 제조데이터셋 개요

구분	내용
제조데이터셋 이름	사출성형기 제조AI데이터셋
제조데이터 활용 목적	사출성형 공정에서 발생하는 품질 문제를 AI 기반으로 해결하기 위해 변수간의 상관관계를 찾고 AI 알고리즘을 통해 사출성형 공정 불량 예측 모델학습
제조데이터 파일명	DWRT_data.csv
제조데이터 변수명	A_NGmark, A_Cushion_Position, A_Max_Injection_Speed, A_Average_Back_Pressure, A_Barrel_Temperature_3, A_Barrel_Temperature_4,
제조데이터 개수	72,762개(변수 21개)
제조데이터 총량	5.5MB

□ 제조데이터셋 수집 방법

구분	내용
업종	사출성형
제조공정명	사출공정
수집장비	사출성형기 5, 6호기(제조사 : 우진플라임)
수집기간	2023년 08월 30일 ~ 2023년 12월 20일
수집주기	20sec

□ 제조데이터셋 정제(전처리) 방법



데이터 전처리 알고리즘 적용 절차

PLC수집된 데이터 중 노이즈 제거 : 아날로그 신호를 디지털로 변환한 센서신호를 받아오고 있어 아날로그 노이즈 신호가 디지털로 변환되어 수집되는 경향이 있어 이 데이터를 경향성 확인 할 수 있는 데이터로 변환

Null값 제거(Null제거 샘플) : 필요 데이터 중 사용자가 입력하지 않아 불량 수량, 양품 수량, 비가동 시간이 NULL로 수집되는 데이터를 0으로 변환하여 학습에 알맞은 데이터로 변환, 또한 미 입력 데이터를 평균 데이터로 변환하여 처리

비가동 중일때의 데이터 제거(비가동 데이터 샘플) : 실시간으로 데이터를 수집하기 때문에 생산하지 않고 비가동 중인 데이터 수집 의 경우는 배제하여 가공

- 데이터 결합
: PLC데이터 + 외부 센서 데이터 + 생산실적 데이터(양품, 불량)


☐ 제조데이터셋 변수 정의

변수명	척도	단위	변수설명	범주값(유효범위)
A_NGmark	명목형		양불구분	0 : 정상, 1 : 불량
A_Cushion_Position	연속형		쿠션위치	REAL
A_Max_Injection_Speed	연속형	RPM	최대사출속도	REAL
A_Average_Back_Pressure	연속형	hpa	평균배압	REAL
A_Barrel_Temperature_3	연속형	°C	유압 : 히터1 전동 : 히터3	REAL
A_Barrel_Temperature_4	연속형	°C	유압 : 히터2 전동 : 히터4	REAL
A_Hopper_Temperature	연속형	°C	호퍼온도	REAL
A_Mold_Temperature_1	연속형	°C	금형온도1	REAL
A_Mold_Temperature_2	연속형	°C	금형온도2	REAL
S_Inj_Velocity_04	연속형	m/s	사출속도4	REAL
S_Inj_Pressure_01	연속형	hpa	사출압력1	REAL
S_Inj_Pressure_04	연속형	hpa	사출압력4	REAL
S_Inj_Position_01	연속형	cm	사출거리1	REAL
S_Hid_Time_01	연속형	sec	보압시간1	REAL
S_Suckback_Position_02	연속형	cm	강제후퇴위치2	REAL
S_Barrel_Temperature_02	연속형	°C	히터온도2	REAL
VALUE1	연속형	°C	금형상판온도	REAL
VALUE2	연속형	°C	금형하판온도	REAL
VALUE3	연속형	°C	호퍼온도	REAL
VALUE4	연속형		호퍼수분율	REAL
VALUE5	연속형	°C	현장온도	REAL

☐ 제조데이터 샘플

A_Cushion_Position	A_Max_Injection_Speed	A_Average_Back_Pressure	A_Barrel_Temperature_3	...	A_NGmark
2.06	349.9	134	222.2	...	0
2.06	349.9	134	221.8	...	0
2.06	349.9	134	221.9	...	0
2.06	349.9	134	221.7	...	0
2.06	349.9	134	221.9	...	0
2.06	349.9	130	222.2	...	0
2.06	349.9	133	222	...	0
2.05	349.9	134	222.1	...	0
2.05	349.9	134	221.8	...	0



3. AI 솔루션 현장적용 결과

□ 모델 성능 결과

- 시계열 딥러닝 모델 활용
 - GRU, LSTM, BiLSTM(양방향 LSTM) 모델 활용
 - 모델 타입: Sequential
 - Layer: 3Stacked Layers(128-64-32)
 - Optimizer: Adam
 - Loss function: Binary Crossentropy
- 모델 성능 결과 요약

순번	알고리즘	모델 성능 (F1-Score)
1	GRU	0.89
2	LSTM	0.87
3	BiLSTM	0.93

- 시계열 모델 중 BiLSTM은 F1-Score는 0.93으로 높은 성능을 보이지만, 유사 모델링 기법과 데이터의 한계로 시계열 모델링의 결과가 유의미하게 나오지 않음
- 시계열에 적합하지 않은 데이터셋 구조와 유사한 모델링 구조로 인해 모델 성능 차이가 나타나지 않음

- 머신러닝 모델 활용
 - LogisticRegression, XGBoost, Decision Tree 모델을 활용하여 디폴트 파라미터로 학습 진행
- LogisticRegression 성능

```

clf = LogisticRegression(random_state=0).fit(X_train, y_train)
y_pred = clf.predict(X_test)

print(classification_report(y_test, y_pred))

# 전체 테스트 데이터에 대한 최종 F1 점수 계산 및 출력
f1 = f1_score(y_test, y_pred, average='weighted') # 'macro'를 사용해도 됩니다.
print("최종 F1 점수:", f1)

```

	precision	recall	f1-score	support
0	0.73	0.75	0.74	20720
1	0.74	0.72	0.73	20720
accuracy			0.74	41440
macro avg	0.74	0.74	0.74	41440
weighted avg	0.74	0.74	0.74	41440

최종 F1 점수: 0.7352305302496634



○ XGBoost 성능

XGBoost

```
X = final_df.drop('A_NGmark', axis=1)
y = final_df['A_NGmark']

X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.1, stratify=y, random_state=42)

xgb_model = XGBClassifier(n_estimators=5000)

xgb_model.fit(X_train, y_train, early_stopping_rounds=500, eval_set=[(X_test, y_test)])

y_pred = xgb_model.predict(X_test)
```

	precision	recall	f1-score	support
0	1.00	1.00	1.00	20720
1	1.00	1.00	1.00	20720
accuracy			1.00	41440
macro avg	1.00	1.00	1.00	41440
weighted avg	1.00	1.00	1.00	41440

최종 F1 점수: 0.9992036678752996

○ Decision Tree 성능

DecisionTree (smote 적용)

```
X = final_df.drop('A_NGmark', axis=1)
y = final_df['A_NGmark']

X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.1, stratify=y, random_state=42)

# 의사결정 트리 모델 정의 및 학습
clf = DecisionTreeClassifier()
clf.fit(X_train, y_train)

y_pred = clf.predict(X_test)
```

	precision	recall	f1-score	support
0	1.00	1.00	1.00	20720
1	1.00	1.00	1.00	20720
accuracy			1.00	41440
macro avg	1.00	1.00	1.00	41440
weighted avg	1.00	1.00	1.00	41440


최종 F1 점수: 0.9977557915044847

○ 모델 성능 결과 요약

순번	알고리즘	모델 성능 (F1-Score)
1	Logistic Regression	0.73
2	XGBoost	0.99
3	Decision Tree	0.99



- 머신러닝의 모델중 XGBoost와 Decision Tree의 F1-Score는 0.99로 Decision Tree의 오답 값이 가장 적었음
- Decision Tree는 양/불 41,440개의 값 중에 81개를 오답으로 예측



□ 최종 모델 선정

- 모델 성능 비교

구분	알고리즘	모델 성능 (F1-Score)
딥러닝 기반	GRU	0.89
	LSTM	0.87
	BiLSTM	0.93
머신러닝 기반	Logistic Regression	0.73
	XGBoost	0.99
	Decision Tree	0.99

- F1-Score 산출 결과 모든 예측 모델 성능이 80% 이상으로 성능 목표 달성
- 성능이 우수하고 모델이 간단한 Decision Tree를 최종 모델로 선정
- Input - Output : 공정 데이터 -> 검사 결과(0/1)



- 분석 모델: Decision Tree
- Decision Tree는 Classification과 Regression 모두 가능한 지도학습 모델 중 하나로 학습을 통해 트리 기반의 분류 규칙을 만드는 알고리즘임
- 정규화나 표준화를 요구하지 않고 범주형과 연속형 변수를 모두 처리할 수 있어 데이터 전처리 요구도가 낮으며 직관적인 트리 구조를 가짐
- 간단하면서도 강력한 알고리즘으로 복잡하거나 상관관계가 크지 않은 데이터에서 높은 성능을 보임
- Decision Tree 알고리즘을 활용하여 입력값으로 각 공정 단계별 센서 값을 입력값으로 받고, 설비의 최종 판정(OK/NG) 값을 예측하는 모델 학습 수행





4. 성과지표 측정 방법

○ 성능 지표(F1-Score)

$$F1\ Score = 2 \times \frac{recall \times precision}{recall + precision}$$

성능 지표

		Predict	
		Positive	Negative
Actual	Positive	TP	FN
	Negative	FP	TN

- TP(true인 값을 true로 예측한 횟수) / AI가 예상한 양품 데이터에서 생산시 양품이 산출된 사례의 수
- TN(false인 값을 false로 예측한 횟수) / AI가 예상한 불량 데이터에서 생산시 불량이 산출된 사례의 수
- FP(false인 값을 true로 예측한 횟수) / AI가 예상한 불량 데이터에서 생산시 양품이 산출된 사례의 수
- FN(true인 값을 false로 예측한 횟수) / AI가 예상한 양품 데이터에서 생산시 불량이 산출된 사례의 수



5. 성과지표 측정 결과

No	성과지표	단위	현재	목표	실적	개선율 (%)	달성률 (%)	가중치	비고
1	Accuracy(데이터 정합률)	%	83	95	100	20%	105%	0.2	사출공정
2	공정 불량률 감소	PPM	4,224	3,500	3,225	31%	108%	0.3	사출공정
3	시간당 생산성	개	1,600	2,000	2,031	27%	102%	0.3	사출공정
4	비가동시간	분/일	464	350	322	44%	108%	0.2	사출공정
종합 달성률							105	1.0	
1. 개선율 1) 증가지표 개선율 = {(실적-현재)/현재} x 100 2) 감소지표 개선율 = {(현재-실적)/실적} x 100 2. 달성률 1) 증가지표 달성도 = (실적/목표) x 100 2) 감소지표 달성도 = {1-(실적-목표)/목표} x 100 3. 종합달성률 = (1번 지표 달성도 X 1번지표 가중치) + (2번 지표 달성도 X 2번지표 가중치) + ... +(n번 지표 달성도 X n번지표 가중치) * 종합달성률 100% 이상이 되어야 정량적 성과지표 달성으로 평가									

정량적 목표달성 결과

- AI최적의 모델을 선정하여 Accuracy 산출

DecisionTree (smote 적용)

```

X = final_df.drop('A_NGmark', axis=1)
y = final_df['A_NGmark']

X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.1, stratify=y, random_state=42)

# 의사결정 트리 모델 정의 및 학습
clf = DecisionTreeClassifier()
clf.fit(X_train, y_train)

y_pred = clf.predict(X_test)

```

	precision	recall	f1-score	support
0	1.00	1.00	1.00	20720
1	1.00	1.00	1.00	20720
accuracy			1.00	41440
macro avg	1.00	1.00	1.00	41440
weighted avg	1.00	1.00	1.00	41440

최종 F1 점수: 0.9977557915044847

Accuracy

1)개선율 (100-83)/83 * 100 = 20

2)달성율 (100/95) * 100 = 105

6. 확장가능성 및 향후 계획

